

Comparação entre Modelagem Física e Árvore de Decisão (ID3) Sistema Massa–Mola–Amortecedor

1 Introdução

Sistemas dinâmicos estão presentes em diversas áreas da engenharia e da ciência aplicada, como controle de vibrações, robótica, sistemas automotivos, estruturas mecânicas e circuitos elétricos equivalentes. Entre esses sistemas, o modelo massa–mola–amortecedor destaca-se por sua simplicidade matemática e por sua capacidade de representar fenômenos reais de forma fiel.

O estudo desse sistema permite compreender conceitos fundamentais como estabilidade, amortecimento, polos do sistema e resposta temporal. Além disso, ele serve como base para sistemas mais complexos modelados por equações diferenciais ordinárias.

Este trabalho tem como objetivo comparar duas abordagens para classificar a estabilidade do sistema:

- Modelagem analítica baseada em equações diferenciais.
- Aprendizado supervisionado utilizando o algoritmo ID3.

A motivação central é investigar se um algoritmo puramente estatístico consegue reconstruir, a partir de dados rotulados, as mesmas fronteiras de decisão obtidas pela análise matemática do sistema.

2 Modelagem Física do Sistema

O sistema massa–mola–amortecedor é descrito pela equação diferencial:

$$m\ddot{x}(t) + b\dot{x}(t) + kx(t) = 0 \tag{1}$$

onde:

- m é a massa,
- b é o coeficiente de amortecimento,
- k é a constante elástica da mola.

Essa equação descreve o equilíbrio entre força inercial, força dissipativa e força restauradora.

2.1 Transformada de Laplace

Aplicando a Transformada de Laplace:

$$ms^2X(s) + bsX(s) + kX(s) = 0 \quad (2)$$

O polinômio característico associado é:

$$ms^2 + bs + k = 0 \quad (3)$$

A análise das raízes desse polinômio permite determinar a estabilidade do sistema.

2.2 Parâmetros Fundamentais

Frequência natural:

$$\omega_n = \sqrt{\frac{k}{m}} \quad (4)$$

Razão de amortecimento:

$$\zeta = \frac{b}{2\sqrt{mk}} \quad (5)$$

Parte real dos polos:

$$\sigma = -\frac{b}{2m} \quad (6)$$

A estabilidade está diretamente relacionada ao sinal da parte real dos polos.

3 Critério de Classificação Física

A classificação do sistema é realizada segundo:

- $\sigma > 0 \Rightarrow$ Instável
- $0 < \zeta < 1 \Rightarrow$ Subamortecido
- $\zeta = 1 \Rightarrow$ Criticamente amortecido
- $\zeta > 1 \Rightarrow$ Superamortecido

Essa regra é determinística e deriva diretamente da estrutura matemática da equação diferencial.

4 Aprendizado Supervisionado com ID3

Diferentemente da abordagem analítica, o algoritmo ID3 não possui conhecimento prévio da física do sistema. Ele recebe apenas exemplos rotulados e busca construir uma árvore de decisão que minimize a incerteza estatística.

Algorithm 1 CLASSIFICACAO_FISICA(m, b, k)

```
1:  $\sigma \leftarrow -b/(2m)$ 
2:  $\zeta \leftarrow b/(2\sqrt{mk})$ 
3: if  $\sigma > 0$  then
4:   return Instavel
5: else if  $0 < \zeta < 1$  then
6:   return Subamortecido
7: else if  $|\zeta - 1| < \varepsilon$  then
8:   return Critico
9: else
10:  return Superamortecido
11: end if
```

4.1 Entropia

A entropia mede o grau de desordem de um conjunto:

$$H(S) = - \sum_{i=1}^n p_i \log_2 p_i \quad (7)$$

Algorithm 2 ENTROPIA(S)

```
1:  $H \leftarrow 0$ 
2: for cada classe  $c$  do
3:    $p \leftarrow |S_c|/|S|$ 
4:   if  $p > 0$  then
5:      $H \leftarrow H - p \log_2 p$ 
6:   end if
7: end for
8: return  $H$ 
```

4.2 Ganho de Informação

$$Gain(S, A) = H(S) - \sum_v \frac{|S_v|}{|S|} H(S_v) \quad (8)$$

Algorithm 3 GAIN(S, A)

```
1:  $H_{total} \leftarrow ENTROPIA(S)$ 
2:  $H_{cond} \leftarrow 0$ 
3: for cada valor  $v$  de  $A$  do
4:    $S_v \leftarrow \{x \in S \mid A(x) = v\}$ 
5:    $peso \leftarrow |S_v|/|S|$ 
6:    $H_{cond} \leftarrow H_{cond} + peso \cdot ENTROPIA(S_v)$ 
7: end for
8: return  $H_{total} - H_{cond}$ 
```

4.3 Construção da Árvore

Algorithm 4 ID3($S, Atributos$)

```
1: if todas instâncias têm mesma classe then
2:   return folha
3: end if
4: if  $Atributos = \emptyset$  then
5:   return classe majoritária
6: end if
7:  $melhor \leftarrow \arg \max_A GAIN(S, A)$ 
8: for cada valor  $v$  de  $melhor$  do
9:    $S_v \leftarrow subconjunto$ 
10:  if  $S_v = \emptyset$  then
11:    adicionar folha majoritária
12:  else
13:    adicionar ID3( $S_v, Atributos - \{melhor\}$ )
14:  end if
15: end for
16: return nó
```

5 Importância da Discretização do Tempo

O modelo físico massa–mola–amortecedor é descrito por uma equação diferencial contínua no tempo:

$$m\ddot{x}(t) + b\dot{x}(t) + kx(t) = 0$$

Essa formulação assume tempo contínuo, isto é, $t \in \mathbb{R}$.

Entretanto, quando implementamos simulações computacionais ou geramos dados para aprendizado de máquina, não é possível trabalhar diretamente com tempo contínuo. Computadores operam de forma discreta. Assim, torna-se necessário discretizar o tempo:

$$t_k = k\Delta t$$

onde Δt é o passo de integração.

5.1 Por que foi necessário discretizar?

A discretização foi necessária por três razões principais:

1. **Simulação Numérica:** Para calcular a resposta temporal usando métodos como Euler ou Runge-Kutta.
2. **Geração de Dataset:** O algoritmo ID3 exige exemplos finitos e estruturados.
3. **Conversão de Modelo Contínuo para Representação Computacional:** O aprendizado supervisionado opera sobre vetores finitos de atributos.

Portanto, a discretização não altera a física do sistema, mas permite que o modelo seja computacionalmente manipulável.

6 Discretização dos Atributos para o ID3

O algoritmo ID3 trabalha com atributos categóricos. Entretanto, as variáveis físicas ζ e σ são contínuas.

Assim, foi necessário transformar variáveis contínuas em categorias simbólicas.

6.1 Motivação

O ganho de informação é calculado a partir de divisões discretas. Se fornecermos valores contínuos diretamente, o algoritmo não saberá onde cortar o espaço sem uma estratégia adicional.

Por isso, foi aplicada uma discretização baseada em conhecimento físico:

- $\sigma > 0 \rightarrow$ “positivo”
- $\sigma \leq 0 \rightarrow$ “negativo”
- $\zeta \approx 1 \rightarrow$ “critico”
- $\zeta > 1 \rightarrow$ “maior_1”
- $0 < \zeta < 1 \rightarrow$ “menor_1”
- $\zeta = 0 \rightarrow$ “zero”

Essa escolha preserva a interpretação física das fronteiras de estabilidade.

7 Integração com o Código Implementado

A função responsável pela transformação dos dados contínuos em categorias simbólicas é apresentada no Algoritmo 5.

Algorithm 5 DISCRETIZAR-DATASET(D)

```
1:  $D' \leftarrow \emptyset$ 
2: for cada linha  $L \in D$  do
3:    $\zeta \leftarrow L[4]$  {Razão de amortecimento}
4:    $\sigma \leftarrow L[5]$  {Parte real dominante}
5:    $c \leftarrow L[6]$  {Classe física real}
6:
7:   if  $\sigma > 0$  then
8:      $cat_\sigma \leftarrow$  “positivo”
9:   else
10:     $cat_\sigma \leftarrow$  “negativo”
11:   end if
12:
13:   if  $|\zeta - 1| < 0.05$  then
14:      $cat_\zeta \leftarrow$  “critico”
15:   else if  $\zeta == 0$  then
16:      $cat_\zeta \leftarrow$  “zero”
17:   else if  $\zeta > 1$  then
18:      $cat_\zeta \leftarrow$  “maior_1”
19:   else
20:      $cat_\zeta \leftarrow$  “menor_1”
21:   end if
22:
23:    $L' \leftarrow \langle cat_\sigma, cat_\zeta, c \rangle$ 
24:    $D' \leftarrow D' \cup \{L'\}$ 
25: end for
26: return  $D'$ 
```

Observe que:

- A discretização utiliza limiares físicos reais para mapear o espaço de estados contínuo.
- O valor $|\zeta - 1| < 0.05$ cria uma banda numérica para tratar a vizinhança do amortecimento crítico.
- O modelo resultante simplifica a entrada para o algoritmo ID3, utilizando apenas o vetor de atributos categóricos $\langle cat_\sigma, cat_\zeta \rangle$.

Observe que:

- A discretização utiliza limiares físicos reais.
- O valor $|\zeta - 1| < 0.05$ cria uma banda numérica para evitar instabilidade computacional.
- O modelo final usa apenas atributos categóricos: $[\sigma_{cat}, \zeta_{cat}]$.

8 Relação Conceitual: Física vs Aprendizado

Há duas camadas distintas no projeto:

8.1 Modelo Físico (Contínuo)

- Baseado em equações diferenciais.
- Tempo contínuo.
- Classificação derivada analiticamente.

8.2 Modelo ID3 (Discreto)

- Baseado em exemplos finitos.
- Atributos categóricos.
- Classificação aprendida por redução de entropia.

A discretização funciona como ponte entre esses dois mundos.

9 Interpretação Estratégica

A discretização não foi apenas uma exigência técnica do algoritmo. Ela teve papel conceitual importante:

- Transformou leis diferenciais em regras simbólicas.
- Converteu dinâmica contínua em lógica booleana.
- Permitiu que o ID3 reconstruísse fronteiras de estabilidade.

Em termos conceituais, o que ocorreu foi:

Equação Diferencial $\rightarrow$ Parâmetros Físicos $\rightarrow$ Categorias $\rightarrow$ Árvore de Decisão

9.1 Visualização do Espaço de Estados e Resposta Temporal

A Figura 1 apresenta a distribuição das classes no espaço de parâmetros (ζ, σ) e a dinâmica temporal correspondente.




Figure 1: À esquerda: Fronteiras de decisão discretizadas pelo modelo. À direita: Resposta no tempo $x(t)$ para amostras do dataset.

A análise visual dos resultados permite extrair as seguintes conclusões:

- **Gráfico da Esquerda (ζ vs σ):** Ele mostra exatamente por que o **Zeta** teve um ganho de informação maior (1.1643). Note como as cores (classes) se organizam em faixas verticais bem definidas em relação ao eixo horizontal (ζ). O **Sigma** (eixo vertical) separa claramente os pontos laranja (Instáveis) na parte superior (> 0).
- **Gráfico da Direita (Respostas Temporais):** Ele dá “vida” aos rótulos. O leitor consegue ver que um ponto classificado como “Subamortecido” (azul) realmente oscila, enquanto um “Instável” (laranja) foge do ponto de equilíbrio, confirmando a classificação física e a previsão do modelo ID3.

10 Resultados e Discussão

A validação do sistema foi realizada utilizando um dataset de 100 amostras geradas aleatoriamente, cobrindo as classes: *Instável*, *Subamortecido*, *Superamortecido*, *Crítico* e *Não amortecido*.

10.1 Análise de Entropia e Ganho de Informação

Os resultados numéricos obtidos demonstram como o algoritmo ID3 prioriza os atributos físicos para reduzir a incerteza estatística:

- **Entropia Total $H(S)$:** 1.4789 (Indica alta diversidade de classes no início).
- **Ganho de Informação σ :** 0.4022.
- **Ganho de Informação ζ :** 1.1643.

Observa-se que o atributo ζ possui um ganho significativamente maior. Isso ocorre porque, enquanto σ separa apenas sistemas estáveis de instáveis, ζ é capaz de subdividir os sistemas estáveis em quatro subcategorias físicas distintas, reduzindo a entropia residual para apenas 0.3146.

10.2 Comparação de Performance

A tabela abaixo apresenta uma amostra das previsões realizadas por ambos os modelos frente aos dados reais do sistema:

Table 1: Comparação entre Classificação Física e Árvore ID3			
Sistema (m, b, k)	Classe Real	Prev. Física	Prev. ID3
1493, -176, 6118	Instável	Instável	Instável
1454, 5727, 25505	Sub	Sub	Sub
1879, 16033, 13430	Super	Super	Super
706, 17974, 5561	Super	Super	Super
1341, -643, 30008	Instável	Instável	Instável

10.3 Acurácia Final

Ambas as abordagens atingiram o desempenho máximo no conjunto de testes:

- **Acurácia do Modelo Físico:** 100.0%
- **Acurácia do Modelo ID3:** 100.0%

Este resultado confirma que a estratégia de discretização adotada foi robusta o suficiente para permitir que o algoritmo de aprendizado de máquina reconstruísse perfeitamente as leis de controle e estabilidade clássica.

11 Conclusão

O presente trabalho demonstrou a convergência entre a análise analítica baseada em polos e o aprendizado estatístico baseado em entropia. Através da implementação de uma versão enxuta do algoritmo ID3 e de uma função de discretização orientada pela física, foi possível observar que:

1. O algoritmo ID3 é capaz de "redescobrir" as fronteiras de decisão da física clássica, desde que os atributos sejam apresentados em uma forma categórica representativa (σ e ζ).
2. O atributo ζ (razão de amortecimento) mostrou-se o maior redutor de incerteza para a classificação detalhada do sistema.
3. A acurácia de 100% em ambas as frentes valida a modelagem matemática e a lógica computacional implementada.

O projeto evidencia que, para sistemas mecânicos determinísticos, a inteligência artificial pode atuar como um espelho fiel das equações diferenciais, oferecendo uma forma alternativa de classificação simbólica.