
Comparação entre Modelagem Física e Árvore de Decisão (ID3)

Sistema Massa–Mola–Amortecedor

Discentes:

Marcio Henrique Matos de Freitas

Marcos Vinicius da Silva Santos

Sumário

1	Introdução	3
2	Modelagem Física do Sistema	3
2.1	Transformada de Laplace	3
2.2	Parâmetros Fundamentais	4
3	Critério de Classificação Física	4
4	Justificativa para Utilização de Dados Sintéticos	4
4.1	Racional Metodológico	5
4.2	Limitações	5
4.3	Algoritmos	5
5	Aprendizado Supervisionado com ID3	5
5.1	Entropia	5
5.2	Ganho de Informação	6
5.3	Construção da Árvore	6
6	Importância da Discretização do Tempo	6
7	Discretização dos Atributos para o ID3	7
7.1	Motivação	7
8	Integração com o Código Implementado	7
9	Relação Conceitual: Física vs Aprendizado	8
9.1	Modelo Físico (Contínuo)	9
9.2	Modelo ID3 (Discreto)	9
10	Interpretação Estratégica	9
10.1	Visualização do Espaço de Estados e Resposta Temporal	9
11	Resultados e Discussão	10
11.1	Análise de Entropia e Ganho de Informação	10
11.2	Comparação de Performance	10
11.3	Acurácia Final	11
12	Conclusão	11

1 Introdução

Sistemas dinâmicos estão presentes em diversas áreas da engenharia e da ciência aplicada, como controle de vibrações, robótica, sistemas automotivos, estruturas mecânicas e circuitos elétricos equivalentes. Entre esses sistemas, o modelo massa–mola–amortecedor destaca-se por sua simplicidade matemática e por sua capacidade de representar fenômenos reais de forma fiel.

O estudo desse sistema permite compreender conceitos fundamentais como estabilidade, amortecimento, polos do sistema e resposta temporal. Além disso, ele serve como base para sistemas mais complexos modelados por equações diferenciais ordinárias.

Este trabalho tem como objetivo comparar duas abordagens para classificar a estabilidade do sistema:

- Modelagem analítica baseada em equações diferenciais.
- Aprendizado supervisionado utilizando o algoritmo ID3.

A motivação central é investigar se um algoritmo puramente estatístico consegue reconstruir, a partir de dados rotulados, as mesmas fronteiras de decisão obtidas pela análise matemática do sistema.

2 Modelagem Física do Sistema

O sistema massa–mola–amortecedor é descrito pela equação diferencial:

$$m\ddot{x}(t) + b\dot{x}(t) + kx(t) = 0 \quad (1)$$

onde:

- m é a massa,
- b é o coeficiente de amortecimento,
- k é a constante elástica da mola.

Essa equação descreve o equilíbrio entre força inercial, força dissipativa e força restauradora.

2.1 Transformada de Laplace

Aplicando a Transformada de Laplace:

$$ms^2X(s) + bsX(s) + kX(s) = 0 \quad (2)$$

O polinômio característico associado é:

$$ms^2 + bs + k = 0 \quad (3)$$

A análise das raízes desse polinômio permite determinar a estabilidade do sistema.

2.2 Parâmetros Fundamentais

Frequência natural:

$$\omega_n = \sqrt{\frac{k}{m}} \quad (4)$$

Razão de amortecimento:

$$\zeta = \frac{b}{2\sqrt{mk}} \quad (5)$$

Parte real dos polos:

$$\sigma = -\frac{b}{2m} \quad (6)$$

A estabilidade está diretamente relacionada ao sinal da parte real dos polos.

3 Critério de Classificação Física

A classificação do sistema é realizada segundo:

- $\sigma > 0 \Rightarrow$ Instável
- $0 < \zeta < 1 \Rightarrow$ Subamortecido
- $\zeta = 1 \Rightarrow$ Criticamente amortecido
- $\zeta > 1 \Rightarrow$ Superamortecido

Essa regra é determinística e deriva diretamente da estrutura matemática da equação diferencial.

4 Justificativa para Utilização de Dados Sintéticos

Neste trabalho, os dados utilizados para treinamento e validação da árvore de decisão não são provenientes de medições experimentais, mas sim gerados sinteticamente a partir do modelo físico clássico do sistema massa–mola–amortecedor, descrito por:

$$m\ddot{x} + b\dot{x} + kx = 0 \quad (7)$$

onde m representa a massa, b o coeficiente de amortecimento e k a constante elástica. A partir desses parâmetros, são calculadas as grandezas físicas relevantes:

$$\omega_n = \sqrt{\frac{k}{m}} \quad (8)$$

$$\zeta = \frac{b}{2\sqrt{mk}} \quad (9)$$

$$\sigma = -\zeta\omega_n \quad (10)$$

A classe do sistema (Subamortecido, Superamortecido, Crítico ou Instável) é determinada diretamente pelas propriedades teóricas associadas aos valores de ζ e σ .

4.1 Racional Metodológico

A utilização de dados sintéticos neste contexto é metodologicamente adequada pelas seguintes razões:

- O objetivo do estudo não é modelar um experimento específico, mas avaliar a capacidade da árvore de decisão em recuperar a estrutura teórica do sistema dinâmico e classificá-lo.
- A classificação é determinística e deriva diretamente das equações físicas.
- A geração aleatória dos parâmetros permite ampla exploração do espaço contínuo (m, b, k) , o que seria impraticável por meio de experimentação real.

4.2 Limitações

Reconhece-se que dados sintéticos não incorporam incertezas experimentais, ruídos de medição ou variações estruturais presentes em sistemas físicos reais. Assim, uma possível extensão futura deste trabalho seria introduzir ruído paramétrico ou utilizar dados experimentais para avaliar a robustez do classificador sob condições não ideais.

4.3 Algoritmos

Algorithm 1 CLASSIFICACAO_FISICA(m, b, k)

```
1:  $\sigma \leftarrow -b/(2m)$ 
2:  $\zeta \leftarrow b/(2\sqrt{mk})$ 
3: if  $\sigma > 0$  then
4:   return Instavel
5: else if  $0 < \zeta < 1$  then
6:   return Subamortecido
7: else if  $|\zeta - 1| < \varepsilon$  then
8:   return Critico
9: else
10:  return Superamortecido
11: end if
```

5 Aprendizado Supervisionado com ID3

Diferentemente da abordagem analítica, o algoritmo ID3 não possui conhecimento prévio da física do sistema. Ele recebe apenas exemplos rotulados e busca construir uma árvore de decisão que minimize a incerteza estatística.

5.1 Entropia

A entropia mede o grau de desordem de um conjunto:

$$H(S) = - \sum_{i=1}^n p_i \log_2 p_i \quad (11)$$

Algorithm 2 ENTROPIA(S)

```
1:  $H \leftarrow 0$ 
2: for cada classe  $c$  do
3:    $p \leftarrow |S_c|/|S|$ 
4:   if  $p > 0$  then
5:      $H \leftarrow H - p \log_2 p$ 
6:   end if
7: end for
8: return  $H$ 
```

5.2 Ganho de Informação

$$Gain(S, A) = H(S) - \sum_v \frac{|S_v|}{|S|} H(S_v) \quad (12)$$

Algorithm 3 GAIN(S, A)

```
1:  $H_{total} \leftarrow ENTROPIA(S)$ 
2:  $H_{cond} \leftarrow 0$ 
3: for cada valor  $v$  de  $A$  do
4:    $S_v \leftarrow \{x \in S \mid A(x) = v\}$ 
5:    $peso \leftarrow |S_v|/|S|$ 
6:    $H_{cond} \leftarrow H_{cond} + peso \cdot ENTROPIA(S_v)$ 
7: end for
8: return  $H_{total} - H_{cond}$ 
```

5.3 Construção da Árvore

6 Importância da Discretização do Tempo

O modelo físico massa–mola–amortecedor é descrito por uma equação diferencial contínua no tempo:

$$m\ddot{x}(t) + b\dot{x}(t) + kx(t) = 0$$

Essa formulação assume tempo contínuo, isto é, $t \in \mathbb{R}$.

Entretanto, quando implementamos simulações computacionais ou geramos dados para aprendizado de máquina, não é possível trabalhar diretamente com tempo contínuo. Computadores operam de forma discreta. Assim, torna-se necessário discretizar o tempo:

$$t_k = k\Delta t$$

onde Δt é o passo de integração.

Algorithm 4 ID3($S, Atributos$)

```
1: if todas instâncias têm mesma classe then
2:   return folha
3: end if
4: if  $Atributos = \emptyset$  then
5:   return classe majoritária
6: end if
7:  $melhor \leftarrow \arg \max_A GAIN(S, A)$ 
8: for cada valor  $v$  de  $melhor$  do
9:    $S_v \leftarrow subconjunto$ 
10:  if  $S_v = \emptyset$  then
11:    adicionar folha majoritária
12:  else
13:    adicionar ID3( $S_v, Atributos - \{melhor\}$ )
14:  end if
15: end for
16: return nó
```

7 Discretização dos Atributos para o ID3

O algoritmo ID3 trabalha com atributos categóricos. Entretanto, as variáveis físicas ζ e σ são contínuas.

Assim, foi necessário transformar variáveis contínuas em categorias simbólicas.

7.1 Motivação

O ganho de informação é calculado a partir de divisões discretas. Se fornecermos valores contínuos diretamente, o algoritmo não saberá onde cortar o espaço sem uma estratégia adicional.

Por isso, foi aplicada uma discretização baseada em conhecimento físico:

- $\sigma > 0 \rightarrow$ “positivo”
- $\sigma \leq 0 \rightarrow$ “negativo”
- $\zeta \approx 1 \rightarrow$ “critico”
- $\zeta > 1 \rightarrow$ “maior_1”
- $0 < \zeta < 1 \rightarrow$ “menor_1”
- $\zeta = 0 \rightarrow$ “zero”

Essa escolha preserva a interpretação física das fronteiras de estabilidade.

8 Integração com o Código Implementado

A função responsável pela transformação dos dados contínuos em categorias simbólicas é apresentada no Algoritmo 5.

Algorithm 5 DISCRETIZAR-DATASET(D)

```
1:  $D' \leftarrow \emptyset$ 
2: for cada linha  $L \in D$  do
3:    $\zeta \leftarrow L[4]$  {Razão de amortecimento}
4:    $\sigma \leftarrow L[5]$  {Parte real dominante}
5:    $c \leftarrow L[6]$  {Classe física real}
6:
7:   if  $\sigma > 0$  then
8:      $cat_\sigma \leftarrow \text{"positivo"}$ 
9:   else
10:     $cat_\sigma \leftarrow \text{"negativo"}$ 
11:   end if
12:
13:   if  $|\zeta - 1| < 0.05$  then
14:      $cat_\zeta \leftarrow \text{"critico"}$ 
15:   else if  $\zeta == 0$  then
16:      $cat_\zeta \leftarrow \text{"zero"}$ 
17:   else if  $\zeta > 1$  then
18:      $cat_\zeta \leftarrow \text{"maior\_1"}$ 
19:   else
20:      $cat_\zeta \leftarrow \text{"menor\_1"}$ 
21:   end if
22:
23:    $L' \leftarrow \langle cat_\sigma, cat_\zeta, c \rangle$ 
24:    $D' \leftarrow D' \cup \{L'\}$ 
25: end for
26: return  $D'$ 
```

Observe que:

- A discretização utiliza limiares físicos reais para mapear o espaço de estados contínuo.
- O valor $|\zeta - 1| < 0.05$ cria uma banda numérica para tratar a vizinhança do amortecimento crítico.
- O modelo resultante simplifica a entrada para o algoritmo ID3, utilizando apenas o vetor de atributos categóricos $\langle cat_\sigma, cat_\zeta \rangle$.

Observe que:

- A discretização utiliza limiares físicos reais.
- O valor $|\zeta - 1| < 0.05$ cria uma banda numérica para evitar instabilidade computacional.
- O modelo final usa apenas atributos categóricos: $[\sigma_{cat}, \zeta_{cat}]$.

9 Relação Conceitual: Física vs Aprendizado

Há duas camadas distintas no projeto:

9.1 Modelo Físico (Contínuo)

- Baseado em equações diferenciais.
- Tempo contínuo.
- Classificação derivada analiticamente.

9.2 Modelo ID3 (Discreto)

- Baseado em exemplos finitos.
- Atributos categóricos.
- Classificação aprendida por redução de entropia.

A discretização funciona como ponte entre esses dois mundos.

10 Interpretação Estratégica

A discretização não foi apenas uma exigência técnica do algoritmo. Ela teve papel conceitual importante:

- Transformou leis diferenciais em regras simbólicas.
- Converteu dinâmica contínua em lógica booleana.
- Permitiu que o ID3 reconstruísse fronteiras de estabilidade.

Em termos conceituais, o que ocorreu foi:

Equação Diferencial $\rightarrow$ Parâmetros Físicos $\rightarrow$ Categorias $\rightarrow$ Árvore de Decisão

10.1 Visualização do Espaço de Estados e Resposta Temporal

A Figura 1 apresenta a distribuição das classes no espaço de parâmetros (ζ, σ) e a dinâmica temporal correspondente.




Figura 1: À esquerda: Fronteiras de decisão discretizadas pelo modelo. À direita: Resposta no tempo $x(t)$ para amostras do dataset.

A análise visual dos resultados permite extrair as seguintes conclusões:

- **Gráfico da Esquerda (ζ vs σ):** Ele mostra exatamente por que o **Zeta** teve um ganho de informação maior (1.1643). Note como as cores (classes) se organizam em faixas verticais bem definidas em relação ao eixo horizontal (ζ). O **Sigma** (eixo vertical) separa claramente os pontos laranja (Instáveis) na parte superior (> 0).
- **Gráfico da Direita (Respostas Temporais):** Ele dá “vida” aos rótulos. O leitor consegue ver que um ponto classificado como “Subamortecido” (azul) realmente oscila, enquanto um “Instável” (laranja) foge do ponto de equilíbrio, confirmando a classificação física e a previsão do modelo ID3.

11 Resultados e Discussão

A validação do sistema foi realizada utilizando um dataset de 100 amostras geradas aleatoriamente, cobrindo as classes: *Instável*, *Subamortecido*, *Superamortecido*, *Crítico* e *Não amortecido*.

11.1 Análise de Entropia e Ganho de Informação

Os resultados numéricos obtidos demonstram como o algoritmo ID3 prioriza os atributos físicos para reduzir a incerteza estatística:

- **Entropia Total $H(S)$:** 1.4789 (Indica alta diversidade de classes no início).
- **Ganho de Informação σ :** 0.4022.
- **Ganho de Informação ζ :** 1.1643.

Observa-se que o atributo ζ possui um ganho significativamente maior. Isso ocorre porque, enquanto σ separa apenas sistemas estáveis de instáveis, ζ é capaz de subdividir os sistemas estáveis em quatro subcategorias físicas distintas, reduzindo a entropia residual para apenas 0.3146.

11.2 Comparação de Performance

A tabela abaixo apresenta uma amostra das previsões realizadas por ambos os modelos frente aos dados reais do sistema:

Tabela 1: Comparação entre Classificação Física e Árvore ID3

Sistema (m, b, k)	Classe Real	Prev. Física	Prev. ID3
1493, -176, 6118	Instável	Instável	Instável
1454, 5727, 25505	Sub	Sub	Sub
1879, 16033, 13430	Super	Super	Super
706, 17974, 5561	Super	Super	Super
1341, -643, 30008	Instável	Instável	Instável

11.3 Acurácia Final

Ambas as abordagens atingiram o desempenho máximo no conjunto de testes:

- **Acurácia do Modelo Físico:** 100.0%
- **Acurácia do Modelo ID3:** 100.0%

Este resultado confirma que a estratégia de discretização adotada foi robusta o suficiente para permitir que o algoritmo de aprendizado de máquina reconstruísse perfeitamente as leis de controle e estabilidade clássica.

12 Conclusão

O presente trabalho demonstrou a convergência entre a análise analítica baseada em polos e o aprendizado estatístico baseado em entropia. Através da implementação de uma versão enxuta do algoritmo ID3 e de uma função de discretização orientada pela física, foi possível observar que:

1. O algoritmo ID3 é capaz de "redescobrir" as fronteiras de decisão da física clássica, desde que os atributos sejam apresentados em uma forma categórica representativa (σ e ζ).
2. O atributo ζ (razão de amortecimento) mostrou-se o maior redutor de incerteza para a classificação detalhada do sistema.
3. A acurácia de 100% em ambas as frentes valida a modelagem matemática e a lógica computacional implementada.

O projeto evidencia que, para sistemas mecânicos determinísticos, a inteligência artificial pode atuar como um espelho fiel das equações diferenciais, oferecendo uma forma alternativa de classificação simbólica.